

Препознавање на текст во слика со OCR

1. Вовед

Оптичкото препознавање знаци (OCR) е технологија која има голем придонес во начинот на кој се справуваме со текст во слики и документи, овозможувајќи автоматска екстракција на текстуални содржини од скенирани документи, слики, рачно напишани текстови и слично. Со дигитализацијата на многу различни индустрии, OCR технологијата има се поголема примена и тоа во повеќе полиња, како на пример дигитализација на документи, автоматизиран внес на податоци, пристапност и друго.

Како истражување на оваа тема, овој проект се фокусира на две популарни OCR алатки, имено Tesseract и EasyOCR, со цел да се евалуира и спореди нивната точност и со тоа да се даде увид во нивната соодветност кога се работи за различни формати на слики и текстови.

2. Што е OCR?

OCR е електронска или механичка конверзија на слики од дигитално напишан, рачно напишан или печатен текст во машински кодиран текст, без разлика дали се од скениран документ, фотографија од документ, слика од знаци и билборди или превод на некој филм. OCR е вообичаен метод за дигитализирање на печатените текстови за да можат електронски да се уредуваат, пребаруваат, складираат покомпактно и др. Рани верзии на OCR се обучувале со слики од секаков вид и се работело на еден фронт одеднаш. Напредните системи се способни да произведат висок степен на точност за повеќето фонтови и имаат поддршка за различни влезни формати на слики. Некои системи се способни да репродуцираат форматиран излез што е приближно ист со оригиналната страница, вклучувајќи слики, колони и други нетекстуални компоненти.

3. Tesseract

Tesseract OCR е една од најпознатите алатки за optical character recognition која била создадена од HP во 1980-тите, а од 2005 е алатка со отворен код која е одржувана од Google и глобална заедница на развивачи. Од создавањето, Tesseract OCR има претрпено повеќе промени од кои најзначајна е воведувањето на методи со невронски мрежи во четвртата верзија.

Првиот чекор во процесот на екстрахирање текст од слика кај Tesseract OCR започнува со претпроцесирање на сликата која може да биде во повеќе формати (пр. PNG, JPEG, TIFF). Сликата се претвора во црно-бел формат и потоа се користи adaptive thresholding

со цел да се бинаризира сликата и со тоа ефективно да се издвои текстот од позадината. Дополнително може да се користат и други методи во претпроцесирање на сликата како дилатација и ерозија на сликата кои најчесто се изведуваат со алатки како OpenCV.

По претпроцесирањето, Tesseract прави сегментација со цел да го анализира распоредот на елементите на сликата. Ова вклучува детекција на текстуални елементи како пасуси, редови, зборови, како и индивидуални знаци (букви, бројки, итн.). Connected component analysis се користи за да се идентификуваат групи на пиксели, сегментирајќи знаци и зборови. Геометриски карактеристики и хевристики асистираат во групирањето на знаците во целини како зборови и редови, а дополнително се користат и техники за одредување на линиите на текстот, односно линијата врз која лежат зборовите.

Препознавањето на текст во Tesseract OCR се темели на LSTM мрежи. LSTM мрежите се тип на RNN (Recurrent Neural Network), мрежи кои користат секвенцијални податоци или податоци од временски серии. Додека традиционалните невронски мрежи кои се карактеристични за длабокото учење претпоставуваат дека влезовите и излезите се меѓусебно независни, излезите во RNN зависат од елементите кои им претходат во секвенцата. Покрај ова, за разлика од други типови на невронски мрежи, карактеристично за RNN е дека параметрите се споделени меѓу секој од слоевите во мрежата, поточно сите слоеви во мрежата го споделуваат истиот тежински параметар. Овие тежини се модифицираат понатаму користејќи backpropagation. Во овој чекор RNN може да најде на два типа на проблем: градиент кој исчезнува или градиент кој „експлодира“. Кога се случува проблемот на градиент кој исчезнува, градиентот е премал и продолжува да се смалува се додека не стане незначаен (0) што резултира во тоа алгоритмот да прекине да учи. Од друга страна, кога градиентот „експлодира“, неговата вредност станува преголема што го прави моделот нестабилен и неговите тежини ултимативно ќе станат преголеми и ќе се репрезентираат со NaN. LSTM како една варијација на RNN нуди решение на проблемот на исчезнување на градиентот. LSTM секвенцијално го процесира секој ред од текстот и генерира веројатносни распределби на можни знаци за секоја позиција во редот. За поголема точност, beam search алгоритмот се користи за да се определи најверојатната секвенца на знаци врз база на излезот од LSTM мрежата. Овој процес ги зема предвид контекстот во кој се наоѓа текстот како и постоечки јазични модели.


Процесот на екстрахирање текст со Tesseract OCR завршува со фазата на постпроцесирање во која се интегрираат јазични модели кои корегираат грешки и воспоставуваат лингвистичка кохерентност, а во некои случаи може да се интегрира и проверка на правопис. Крајниот текст Tesseract може да го генерира во повеќе формати како plain text, hOCR (HTML-based), PDF, или ALTO (XML шема за OCR резултати).

4. EasyOCR

EasyOCR е библиотека со отворен код за optical character recognition(OCR) која го олеснува извлекувањето текстуални информации од слики на различни јазици и скрипти. Развиен од тимот на Jaided AI, EasyOCR користи техники на длабоко учење за прецизно идентификување и транскрипција на текст од сложени позадини и различни фонтови. Неговата едноставност и леснотија на користење го прават особено привлечен за програмерите и истражувачите во областа на обработка на слики. Со поддршка за над 80 јазици, вклучувајќи ги и оние со сложени групи на знаци како што се кинески, јапонски и корејски, EasyOCR се издвојува по својата разноврсност. Библиотеката беспрекорно се интегрира со Python, овозможувајќи им на корисниците брзо и лесно да имплементираат OCR во своите проекти. Со користење на претходно обучени модели, EasyOCR може да испорача висока точност без да бара обемни податоци за обука, што го прави моќна алатка за задачи како што се дигитализирање документи, извлекување информации од ознаки и овозможување пребарување базирано на текст во мултимедијална содржина. Дополнително, активната заедница тековно ја ажурира библиотеката со што се гарантира дека таа останува робусно и сигурно решение за потребите на OCR во постојано развивачкиот пејзаж на обработка на слики.

4.1. Компоненти на EasyOCR

EasyOCR се состои од три компоненти: екстракција на карактеристики, означување на секвенци и декодирање. Со цел да се извлечат корисни функции од влезната слика, моделите за длабоко учење како што се ResNet и VGG се користат во екстракција на карактеристики. Овие карактеристики се од суштинско значење за препознавање текст во слики. Вториот чекор, означувањето на секвенци, користи Long Short-Term Memory (LSTM) мрежи за да го интерпретира секвенцијалниот контекст на извлечените карактеристики. Препознавањето и структурирањето на шаблоните на текст се клучни задачи за LSTM мрежите. Конечно, делот за декодирање ги дешифрира и транскрибира означените секвенци во вистинскиот препознаен текст користејќи Connectionist Temporal Classification (CTC) алгоритам. Овие три елементи функционираат како единка за да му овозможат на EasyOCR веродостојно и ефикасно да извлекува текст од сликите. Тренирачкиот pipeline е базиран врз основа на deep-text-recognition-benchmark framework кој го подобрува препознавањето на текст во слики и претставува силна база за извршувањето на OCR.



1. Екстракција на карактеристики (Resnet и VGG):

Првиот чекор на моделот за препознавање е екстракција на карактеристики. За да се создаде збир на карактеристики што може да се користат за дополнителна анализа, влезните податоци мора да се конвертираат. За таа цел се користат VGG и Resnet.

Resnet, или Residual Network, е convolutional neural network (CNN) кој заобиколува одредени слоеви со користење на кратенки или прескокнување конекции. Ова овозможува мрежата да биде подлабока и сепак да може да биде тренирана со решавање на проблемот на исчезнувачки градиенти. Учењето на резидуално репрезентативните функции наместо директно претставување на сигналот е фундаменталниот принцип на архитектурата на Resnet. Ова ја намалува сложеноста на моделот и го олеснува процесот на учење на мрежата.

Дополнителен вид на CNN е Visual Geometry Group или VGG. Неговата униформна архитектура и едноставност се добро познати. Неговата хомогена архитектура се состои од многу мали (3x3) конволуциони филтри наредени се подлабоко и подлабоко еден врз друг. Ова го поедноставува разбирањето и модификацијата на мрежата со намалување на бројот на пресметувања и параметри.

2. Означување на секвенца (LSTM):

Следниот чекор е означување на секвенцата. За ова се користат Long Short-Term Memory (LSTM) мрежи.

RNN мрежи од типот на учење и меморизација со долга секвенца, или LSTM, се способни да ги моделираат временските зависности од повеќе временски чекори. Различниот дизајн на LSTM, за разлика од конвенционалните RNN, помага во спречување на проблемот на исчезнувачки градиенти. Мемориската ќелија со трите различни видови порти - влез, заборавале и излез - и овозможуваат да го постигне тоа. Овие елементи му даваат на LSTM голема ефикасност за задачите за означување на секвенци со тоа што му овозможуваат да додава или отстранува информации од состојбата на ќелијата преку проширени секвенци.

3. Декодирање (CTC):

Декодирањето е последниот чекор во моделот за препознавање, а за ова се користи Connectionist Temporal Classification (CTC).

Еден вид на функција на загуба наречена CTC се применува на секвенцни проблеми кај кои времето е несигурно. Се применува во ситуации кога не сме сигурни за усогласувањето помеѓу ознаките и влезните податоци, што често се случува при препознавање на ракопис. Со цел да обезбеди предвидување со променлива должина, CTC додава празна ознака покрај постоечките ознаки. Потоа е совршен за декодирање

со OCR бидејќи ја пресметува загубата со собирање на сите можни порамнувања на влезот до целните секвенци.

Променетата верзија на deep-text-recognition-benchmark framework служи како pipeline за обука за препознавањето кое го извршува EasyOCR. Со употреба на овој framework, моделите за препознавање текст може да се обучат на различни сетови на податоци, што го прави EasyOCR неверојатно разноврсен и ефикасен.

5. Компарација помеѓу Tesseract и EasyOCR

EasyOCR и TesseractOCR се разликуваат на неколку начини. TesseractOCR првенствено користи традиционален пристап заснован на машинско учење и поддржува голем број јазици. Сепак, неговата прецизност може да страда со сложени слики, особено во случаи на неправилни фонтови или бучни позадини, што бара претходна обработка за оптимални резултати.

EasyOCR, од друга страна, користи модели за длабоко учење, особено конволуциони невронски мрежи (CNN), за да ја подобри точноста на OCR, особено со тешки фонтови, ротиран текст или нелатински скрипти. EasyOCR има поголема способност за справувањето со необични, сложени сценарија за препознавање текст. Иако TesseractOCR е полесен и широко поддржан, EasyOCR често обезбедува подобра прецизност, особено во разновидните и предизвикувачки задачи за препознавање текст во слики, иако по цена на поголема процесирачка моќ.

5. 1. Разлики во LSTM мрежите на Tesseract и EasyOCR

1. LSTM во Tesseract

Користење на LSTM мрежи игра клучна улога во подобрувањето на препознавањето на текст, особено за повеќејазични документи, сложени фонтови или искривен текст.

LSTM во Tesseract работи на следниот начин:

- **Обработка на влез**

Влезната слика е поделена на региони во вид на мрежи, каде што секоја мрежа содржи мал сегмент од текстот. Карактеристиките од овие мрежи се извлекуваат и се користат како влез за LSTM.

- **LSTM слој**

Овие извлечени карактеристики се внесуваат во LSTM мрежа, која ја обработува низата од карактери. Слојот LSTM гарантира дека контекстот на околните знаци се користи за да се подобри точноста на препознавањето.

- **Обука**

LSTM моделите на Tesseract се обучени на големи бази на податоци од означени текстуални слики, овозможувајќи и на мрежата да научи шеми, фонтови и различни стилови на ракопис. Моделот LSTM учи да препознава знаци врз основа на контекстот на соседните знаци, подобрувајќи ја прецизноста во предизвикувачки случаи како курзивно пишување или деградиран текст.

- **Излезен слој**

По обработката на секвенцата, LSTM мрежата враќа препознаени знаци. Оваа низа знаци потоа се обработува (на пр., проверка на правопис) за да се поправат потенцијалните грешки при препознавање.

2. LSTM во EasyOCR

EasyOCR во неговата архитектура обично комбинира CNN за екстракција на карактеристики и LSTM за моделирање на секвенца.

LSTM во EasyOCR работи на следниот начин:

- **Обработка на влезна слика**

Влезната слика прво се обработува со помош на конволуциона невронска мрежа - CNN. CNN извлекува визуелни карактеристики од сликата, како што се рабови, текстури и форми, шеми кои се слични на знаци, кои претставуваат различни делови од текстот.

- **Учење низа по низа**

Излезот на CNN се внесува во LSTM слој, кој ја третира сликата како низа од карактеристики, слично на тоа како Tesseract ја разделува сликата во мрежи. Овој LSTM слој ја обработува низата извлечени карактеристики и ги учи зависностите меѓу нив.

- **Двонасочен LSTM**

EasyOCR користи двонасочен LSTM, кој ја обработува низата и од лево кон десно и од десно кон лево, дополнително подобрувајќи ја контекстната свест за моделот. Ова е клучно за препознавање текст, бидејќи одредени букви или зборови може да изгледаат двосмислено кога се гледаат изолирано, но може лесно да се препознаат кога се разгледува контекстот.

- **Загуба на CTC - Конекционистичка временска класификација**

За да се усогласи низата карактеристики со излезните знаци, EasyOCR користи губење на CTC за време на тренингот. Загубата на CTC е дизајнирана за проблеми базирани на секвенца каде што не е познато усогласувањето помеѓу влезот и излезот, на пр. препознавање на знаци во слика. Тоа помага да се најде најдобрата можна низа на знаци што одговара на влезната слика.

- **Краен излез**

Штом секвенцата ќе се обработи од LSTM мрежата, моделот ги прикажува препознаените знаци. EasyOCR, исто така, обезбедува оценка за доверба за препознавање, confidence level, помагајќи му на корисникот да оцени колку се точни предвидувањата.

6. Споредба на резултатите од двата алгоритми

За да направиме споредба на точноста на добиените резултати, односно добиениот текст од двата алгоритми, потребно е прво да одредиме како ќе ја пресметуваме таа точност. За ова ќе користиме метрика наречена растојание на Левенштајн.

6.1. Определување точност: Расотјание на Левенштајн

Со цел да се квантифицираат резултатите од двата алгоритми и тие да може да се споредат се користи растојанието на Левенштајн како мерка за точност при екстрахирање на текст од слика. Растојанието на Левенштајн претставува мерка за сличност помеѓу две низи од карактери која ги зема предвид бројот на карактери кои треба да се додадат, одземат или заменат за едната низа да стане идентична на другата. За да се долови овој принцип може да се земат зборовите “kitten” и “sitting”, чие левенштајново растојание е 3, со оглед на тоа што треба да се направат три промени за едниот збор да се претвори во другиот. Промените се прават во следниве 3 чекори:

1. kitten → sitten (замена на “k” со “s”)
2. sitten → sittin (замена на “e” со “i”)

3. sittin $\rightarrow$ sitting (додавање на “g”)

Математички претставено, растојанието на Левенштајн се пресметува со следнава рекурзивна функција по делови:

$$\text{lev}_{a,b}(i, j) = \begin{cases} \max(i, j) & \text{if } \min(i, j) = 0, \\ \min \begin{cases} \text{lev}_{a,b}(i-1, j) + 1 \\ \text{lev}_{a,b}(i, j-1) + 1 \\ \text{lev}_{a,b}(i-1, j-1) + 1_{(a_i \neq b_j)} \end{cases} & \text{otherwise.} \end{cases}$$

Во оваа формула, a и b се низите на карактери кои се споредуваат, а i и j се позициите на терминалните карактери од соодветните низи (позициите на карактерите почнуваат со реден број 1). Според формулата доколку една од должините е 0, резултатот ќе биде должината на другата низа. Променливите a_i и b_j ги означуваат карактерот од низа a на позиција i и карактерот во од низа b на позиција j , соодветно. Оваа проверка се прави со цел да се знае дали треба да се додаде 1 доколку е потребна промена во низата.


Дополнително на ова, растојанието на Левенштајн може да се пресмета со матрица каде бројот на редови и колони се определува според должината на двата зборови. Матрицата се пополнува по редови од лево на десно и конечното растојание е долниот десен елемент на матрицата. За пример, вака би изгледала пополнетата матрица за зборовите “kitten” и “sitting”.

		k	i	t	t	e	n
	0	1	2	3	4	5	6
s	1	1	2	3	4	5	6
i	2	2	1	2	3	4	5
t	3	3	2	1	2	3	4
t	4	4	3	2	1	2	3
i	5	5	4	3	2	2	3
n	6	6	5	4	3	3	2
g	7	7	6	5	4	4	3


6.2 Споредба на детекција на текст (пример слики)

Следните слики се репрезентација за тоа како секој од алгоритмите го препознаваат текстот на самата слика.



EasyOCR



Tesseract







6.2 Споредба на точност без претпроцесирање

По споредба на текстот прочитан со EasyOCR и вистинскиот текст кој се наоѓа на прикажаните слики, се добива точност од 40.45%. Доколку истата пресметка ја направиме за сите слики кои се наоѓаат во базата, вкупно 423 слики, добиваме точност од 33.39%.

По споредба на текстот прочитан со Tesseract од прикажаните слики, добиваме точност од 12.85%, а за текстот кој се наоѓа на сите слики, добиваме точност од 7.27%.

Ќе направиме и споредба за извлекување на текст од слики на документи. Неколку примери од документите се прикажани на сликите подолу.

Metabolism of S-nicotine in noninduced and Aroclor-induced rats

G. SCHMERS, K. RUTTENBERG, R.-A. WALK, and U. HACKENBERG
IBMPD Institut für Biologische Pharmazie, Cologne, Germany

Received for publication: July 15, 1990

Keywords: Nicotine, urinary metabolites, excretion kinetics, Aroclor induction, sex differences, monoamine oxidase

SUMMARY

The urinary excretion of nicotine and its metabolites in noninduced and Aroclor-induced male and female rats has been determined following intravenous administration of 14 C-labeled S-nicotine at a dose of 40 mg/kg. Complete recovery of the administered radioactivity was achieved. The urinary excretion of nicotine and its metabolites was determined in the urine, blood, and feces. The urinary excretion of nicotine and its metabolites was determined in the urine, blood, and feces. The urinary excretion of nicotine and its metabolites was determined in the urine, blood, and feces.

INTRODUCTION

Nicotine metabolism has been extensively studied, and more than 20 different metabolites resulting from 2 different metabolic pathways have been described (for review, see [1-5]). The metabolism of the naturally occurring S-enantiomer and of the synthetic R-enantiomer of nicotine were shown to be different in vitro [6] as well as in vivo [7], and one enantiomer was found to be metabolized by the metabolites of the other [8]. In the present study, the metabolism of S-nicotine was investigated in noninduced and Aroclor-induced rats.

It is known that the metabolism and toxicology of nicotine are influenced by genetic (e.g., strain, sex) and environmental factors (e.g., drug treatment, diet) [reviewed in 9, 10], which can affect the metabolic rates of the metabolizing enzymes. The influence of substrate inhibition of various cytochrome P-450 isozymes, e.g., phenobarbital, 3-methylcholanthrene, 3-methylcholanthrene, or ethanol on nicotine metabolism has been shown in vitro on subcellular fractions or isolated organs [e.g., [11-13]]. In vivo, the influence of

Phase and copyright request to: Dr. Wolfgang Schmers, IBMPD Institut für Biologische Pharmazie, Postfach 101559, D-5000 Köln, Germany

20087282

BIOGRAPHICAL SKETCH

Name: Schnaper, H. William
Birthdate: 3/16/50
Education: Degree Year Field of Study
 Yale University, New Haven, CT B.A. 1971 Philosophy
 University of Maryland, Baltimore, MD M.D. 1975 Medicine
Experience:
 1975 Intern in Pediatrics, Mount Sinai Medical Center, New York, NY
 1976-78 Resident in Pediatrics, Mount Sinai Medical Center, New York, NY
 1977-78 Chief Resident and Instructor in Pediatrics, Mount Sinai Medical Center and Mount Sinai School of Medicine, New York, NY
 1978-80 Physician, National Health Service Corps, U.S. Public Health Services, Chicago, IL
 1980-82 Fellow in Pediatrics (Nephrology), St. Louis Children's Hospital and Washington University School of Medicine, St. Louis, MO
 1982-83 Instructor in Pediatrics, Washington University School of Medicine, St. Louis, MO
 1982- Assistant Attending in Pediatrics, St. Louis Children's Hospital and Barnes Hospital, St. Louis, MO
 1982- Adjunct in Pathology, The Jewish Hospital of St. Louis, St. Louis, MO
 1983- Assistant Professor of Pediatrics, Washington University School of Medicine, St. Louis, MO
Certifications:
 1980 American Board of Pediatrics
 1982 American Board of Pediatrics, Sub-board in Nephrology
Memberships and Awards:
 1981-82 National Kidney Foundation Research Fellowship Award
 1982-83 National Kidney Foundation of Eastern Missouri and Metro East Fellowship Award
 1983 International Society of Nephrology
 1984 Clinical Investigator Award, NIDDK
 1984 American Society of Pediatric Nephrology
 1985 American Association of Immunologists
 1985 American Society of Nephrology
Publications:
 Schnaper, H.W., R.E. Cole, F.J. Hodges, and A.M. Robson. 1982. Cerebral cortical atrophy in pediatric patients with end-stage renal disease. *Am. J. Kid. Dis.* 2:648.
 Schnaper, H.W., T.M. Aude and C.W. Pierce. 1983. Suppressor T cell activation by human leukocyte interferon. *J. Immunol.* 131:2301.

50182383

-----Original Message-----

From: Mao, Yuqian Y.
Sent: Wednesday, February 28, 2001 11:18 AM
To: Galindo, Cheryl
Cc: Byerley, Janette; Cusato, Denise; Fernandez, Henry L.; Manning, Michelle P.; Balgley, Annemarie
Subject: GIFTS training

Cheryl,

Per my conversation with Annemarie and Janette, I'd like to schedule GIFTS training for Michelle Manning and Denise Cusato. Would you provide a couple of available time slots and I'll coordinate with Michelle and Denise to set up a training time and location?

Also, neither Michelle nor Denise had the passwords for the GIFTS yet. Would you issue them the passwords before the training? Thanks. Yuqian

Yuqian Mao
 Youth Smoking Prevention Programs
 Tel: 917-663-2937
 Yuqian.Y.Mao@pmusa.com

2084391902B

Точноста на документите ја добивме со процесирање на три различни вида на документи, електронска пошта, резиме и научни трудови. По споредба на точниот текст од документите со резултатите од процесирањето на алгоритмите, со Tesseract добивме точност од 90%, а со EasyOCR добивме точност од 77%.

Очекувано е EasyOCR да има поголема точност кога станува збор за слики од секојдневието, бидејќи EasyOCR општо има поголема точност. Tesseract има поголема точност кога станува збор за процесирање документи, што е исто така очекуваниот резултат, со оглед на тоа што Tesseract е дизајниран да работи најдобро со документи и со пасуси на текст, и најдобро работи со слики кои немаат многу бучава. Сепак, ова ниво на точност воопшто не е задоволително, кога станува збор за слики од општ тип.

Оваа точност се однесува на текстот кој алгоритмите можат да го прочитаат. Проблемот е во тоа што EasyOCR, а особено Tesseract, не го пронаоѓаат целиот текст кој постои на

сликата. Текстот кој го детектираат има доста висока точност, но бидејќи не детектираат се што треба да детектираат, целокупната точност драстично опаѓа.

Пресметките кои ги правевме досега се резултат на користење на алгоритмите директно на оригиналните слики, без никаков вид на претпроцесирање. Со цел да добиеме подобри резултати, ќе искористиме неколку техники на претпроцесирање на сликите за да ја зголемиме точноста.

6.3. Претпроцесирање

Со цел да се подобри точноста на Tesseract и EasyOCR се имплементира претпроцесирање на сликите со помош на OpenCV, библиотека за компјутерска визија и машинско учење.

```
def preprocess_image_2_1(image_id):
    path = source_folder + image_id + '.jpg'
    img = cv2.imread(path)
    gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)
    contrast_enhanced = cv2.convertScaleAbs(gray, alpha=2.0, beta=20)
    denoised_image = cv2.fastNlMeansDenoising(contrast_enhanced, None, h=8, templateWindowSize=7, searchWindowSize=21)
    edges = cv2.Canny(denoised_image, threshold1=50, threshold2=150)
    kernel_sharpening = np.array([[0, -0.5, 0], [-0.5, 3, -0.5], [0, -0.5, 0]])
    sharpened_image = cv2.filter2D(denoised_image, -1, kernel_sharpening)
    sharpened_edges = cv2.bitwise_and(sharpened_image, sharpened_image, mask=edges)
    final_image = cv2.addWeighted(denoised_image, alpha=0.8, sharpened_edges, beta=0.2, gamma=0)
    return final_image
```

Првиот чекор во претпроцесирањето на сликата (откога таа ќе се прочита) е конверзија од BGR формат (OpenCV ги чита сликите во BGR, а не во RGB формат) во GRAY. Со ова сликата станува црно-бела, поточно секој пиксел содржи единствено информација за интензитет која е во интервалот од 0 (црно) до 255 (бело). Следствено, ова го поедноставува понатамошното процесирање на сликата и ја намалува комплексноста.

По претворањето на сликата во grayscale се продолжува со зголемување на контрастот на сликата. За оваа цел се користи командата `cv2.convertScaleAbs(gray, alpha=1.1, beta=15)`, каде параметарот `alpha` ги скалира вредностите на пикселите, додека `beta` поставува константна вредност за интензитетот на пикселите. Со други зборови, `alpha` параметрот го зголемува контрастот, додека `beta` ја осветлува сликата.

Следниот чекор во обработката на сликата е намалување на шумот. Во овој дел е важен параметарот `h` кој определува колку ќе биде силен филтерот кој ќе се примени врз сликата. Дополнителните параметри `templateWindowSize` и `searchWindowSize` ја определуваат големината на прозорецот за предвидување на шум и големината на прозорецот за пребарување на слични пиксели, соодветно.

Сликата од која е отстранет шумот понатаму се процесира со тоа што се прави детекција на рабови користејќи го Canny алгоритмот. Во овој чекор се даваат вредности за прагови кои во сликата пронаоѓаат силни и меки рабови.

Во претпоследниот чекор од претпроцесирањето сликата се изострува со тоа што се дефинира kernel кој ги амплифицира рабовите со тоа што ги одзема вредностите на соседните пиксели од вредноста на централниот пиксел. Потоа се корисити `cv2.filter2D` со цел да се примени филтерот за изострување на сликата.

Изострената слика се комбинира со самата себе со рабовите како маска користејќи `bitwise_and`. Оваа операција ги задржува заострените региони каде што има рабови додека ги супресира регионите на сликата каде што нема рабови.

За крај двете слики, `denoised_image` и `sharpened_edges` се комбинираат со соодветни тежини за да се добие финалната слика.

Со ова се завршува претпроцесирањето на сликата и се продолжува со екстрахирање на текст и определување на точност.

6.4. Резултати со претпроцесирање

По процесирање на сите слики, со EasyOCR добиваме точност од 30.22%, а со Tesseract добиваме точност од 7.07%. Може да се воочи дека точноста за двата алгоритми е помала откога ги користевме алгоритмите без никаков вид на мануелно претпроцесирање. Едно објаснување за ова е фактот што се прави двојно претпроцесирање на сликата. Првото претпроцесирање е дефинирано од наша функција која користи неколку методи од OpenCv2 библиотеката за да ја процесира сликата, а потоа се повикуваат алгоритмите, кои сами по себе прават претпроцесирање на сликата, за кое нема опција да се избегне, поради што во општ случај точноста се намалува. Целокупната точност се намалува, но за одредени слики, точноста е подобра со користење на претпроцесирање.







7. Максимална точност

По користење на неколку различни функции за претпроцесирање, во кои секоја се разликуваше во тоа кои методи од cv2 библиотеката се користени за претпроцесирање на сликата, најголемата точност која ја добивме е со комбинација на процесирање слики без никакво претпроцесирање, само користење на алгоритмот директно врз сликата, со што всушност се користи само претпроцесирањето кое е дел од самите алгоритми, и со користење на функцијата за претпроцесирање која е објаснета погоре, во зависност од тоа дали се добива поголема точност за конкретната слика со или без претпроцесирање. Со ваквото „хибридно“ процесирање, добиваме точност од 35.02% со EasyOCR, односно 9.24% со Tesseract, што е 1.63%, односно 1.97% подобро за EasyOCR и Tesseract, соодветно. Кога станува збор за точноста на документите по

користење на претпроцесирање, точноста е многу полоша, 57% со Tesseract и 49% со EasyOCR, по што не вреди да се разгледува ова како опција за хибридно процесирање. Идеално би се користеле различни методи за претпроцесирање во зависност од сликата, односно метод кој одредува колку претпроцесирање е потребно за да се извлече најголема можна точност од сликата, бидејќи не секој чекор од претпроцесирање придонесува за зголемување на точноста во општ случај. Поради тоа, може да заклучиме дека претпроцесирањето кое го користат самите алгоритми е одбрано со добра причина. Не постои општо правило за претпроцесирање кое важи за зголемување на точноста на секоја слика, затоа претпроцесирањето кое се извршува од самите алгоритми, во општ случај е најповолно.

8. Заклучок

Земајќи ги предвид сите добиени резултати во оваа анализа, може да се заклучи дека двете OCR алатки, Tesseract и EasyOCR, имаат предности во различни контексти. Имено, Tesseract дава одлични резултати кога се работи за скенирани документи од различни типови, каде EasyOCR дава задоволителна, но, сепак пониска, точност. Од друга страна, кога се работи за слики кои се земени од секојдневен контекст и не се добро форматирани како печатен документ, EasyOCR дава подобри резултати од Tesseract. Сепак, вреди да се каже дека кога се работи за слики со неформатиран текст, двете технологии имаат проблеми со екстрахирање на текст, односно ниедна од нив не дава точност која би била задоволителна во практична употреба. Со цел да се соочиме со овој проблем, во овој проект се обидовме да ги зголемиме перформансите на технологиите со претпроцесирање на сликата што ја подобрува точноста на индивидуални слики, но на глобално ниво на базата не прави голема разлика во точноста. Ултимативно, може да се заклучи дека додека OCR алатките се справуваат добро со форматиран текст, тие не се доволно тренирани за да можат успешно да се справат со огромниот број на различни контексти кои произлегуваат од слики со ограничен квалитет.